

Proje 5 – Veri Temizleme ve ETL Süreçleri Tasarımı

DBMS	Microsoft SQL Server 2022
Örnek Veri	Hatalı CSV satış verisi → VeriAmbarı
Yöntem	Extract · Transform · Load
Video	(çekildikten sonra eklenecek)

1. Amaç ve Kapsam

ETL (Extract – Transform – Load) süreci; farklı kaynaklardan gelen ham ve hatalı verinin çekilmesi, temizlenip standartlaştırılması ve hedef veritabanına yüklenmesidir. Bu projede hatalı bir satış CSV'si bir ara (staging) tabloya alınmış, T-SQL ile temizlenmiş ve normalize edilmiş bir veri ambarına yüklenmiştir.

- **Extract:** Hatalı CSV'yi staging tabloya alma.
- **Transform:** Eksik/tutarsız/yanlış formatlı verileri temizleme.
- **Load:** Temiz veriyi normalize hedef ambara yükleme.
- **Kalite Raporu:** Temizleme öncesi/sonrası karşılaştırma.

2. Senaryo ve Hatalı Veri Kaynağı

Farklı şubelerden gelen satış kayıtları tek CSV'de birleştirilmiş; veri girişi hatalarıyla dolu.

`satisslar_ham.csv` dosyasının içeriği:

CSV

```
SatisID,Musteri,Email,Sehir,Tutar,Tarih,UrunKategori
1, Ahmet Yilmaz ,ahmet@mail.com,istanbul,1.250,00,2024-03-01,Elektronik
2,ayse demir,AYSE@MAIL.COM, ISTANBUL ,990,2024/03/02,elektronik
3,Mehmet,gecersiz-email,Ankara,, 2024-03-03 ,Giyim
4,Ahmet Yilmaz,ahmet@mail.com,Istanbul,1250,2024-03-01,Elektronik
5,Fatma Kaya,fatma@mail,izmir,-50,32-13-2024,giyim
6,,bos@mail.com,Bursa,750,2024-03-05,
```

Tespit edilen veri kalitesi problemleri:

Problem	Örnek
Baş/son boşluk	" Ahmet Yılmaz ", " ISTANBUL "
Tutarsız büyük/küçük harf	istanbul / ISTANBUL / Istanbul
Sayı formatı tutarsızlığı	1.250,00 / 990 / 1250
Geçersiz e-posta	gecersiz-email / fatma@mail
Eksik (NULL) değer	Tutar, Müşteri, Kategori boş
Geçersiz tarih	2024/03/02 / 32-13-2024
Negatif tutar	-50
Yinelenen kayıt	SatisID 1 ve 4 aynı

3. Hedef Şema (Data Warehouse)

SQL

```
CREATE DATABASE VeriAmbari;
GO
CREATE TABLE dbo.DimMusteri (
    MusteriKey INT IDENTITY(1,1) PRIMARY KEY,
    AdSoyad NVARCHAR(100) NOT NULL, Email NVARCHAR(150) NULL, Sehir NVARCHAR(50) NULL);
CREATE TABLE dbo.DimKategori (
    KategoriKey INT IDENTITY(1,1) PRIMARY KEY, KategoriAdi NVARCHAR(50) NOT NULL UNIQUE);
CREATE TABLE dbo.FactSatis (
    SatisKey INT IDENTITY(1,1) PRIMARY KEY,
    MusteriKey INT NOT NULL REFERENCES dbo.DimMusteri(MusteriKey),
    KategoriKey INT NOT NULL REFERENCES dbo.DimKategori(KategoriKey),
    Tutar DECIMAL(12,2) NOT NULL, SatisTarihi DATE NOT NULL);
GO
```

Commands completed successfully.

VeriAmbari olusturuldu. 3 tablo (DimMusteri, DimKategori, FactSatis) hazır.

► MESAJLAR (MESSAGES)

4. Bölüm A – EXTRACT

4.1 Staging tablosu + CSV yükleme

SQL

```
CREATE TABLE dbo.Staging_Satis (  
    SatisID NVARCHAR(20), Musteri NVARCHAR(200), Email NVARCHAR(200),  
    Sehir NVARCHAR(100), Tutar NVARCHAR(50), Tarih NVARCHAR(50), UrunKategori NVARCHAR(100));  
  
BULK INSERT dbo.Staging_Satis  
FROM 'C:\ETL\data\satislar_ham.csv'  
WITH (FIRSTROW=2, FIELDTERMINATOR=';', ROWTERMINATOR='0x0a', CODEPAGE='65001');  
  
SELECT * FROM dbo.Staging_Satis;
```

SatisID	Musteri	Email	Sehir	Tutar	Tarih	UrunKategori
1	Ahmet Yilmaz	ahmet@mail.com	istanbul	1.250,00	2024-03-01	Elektronik
2	ayse demir	AYSE@MAIL.COM	ISTANBUL	990	2024/03/02	elektronik
3	Mehmet	gecersiz-email	Ankara	NULL	2024-03-03	Giyim
4	Ahmet Yilmaz	ahmet@mail.com	Istanbul	1250	2024-03-01	Elektronik
5	Fatma Kaya	fatma@mail	izmir	-50	32-13-2024	giyim
6	NULL	bos@mail.com	Bursa	750	2024-03-05	NULL

(6 rows affected) — Ham veri kayıpsız alındı; tüm problemler hâlâ görünüyor.

► SONUÇ (RESULTS)

5. Bölüm B – TRANSFORM

5.1 Boşluk, harf standardı, sayı ve tarih dönüşümü + hata işaretleme

SQL

```
INSERT INTO dbo.Stg_Temiz (SatisID, AdSoyad, Email, Sehir, Tutar, SatisTarihi, Kategori, HataNotu)
SELECT
    TRY_CAST(LTRIM(RTRIM(SatisID)) AS INT),
    NULLIF(LTRIM(RTRIM(Musteri)), ''),
    CASE WHEN LOWER(LTRIM(RTRIM(Email))) LIKE '%_@_%._%'
        THEN LOWER(LTRIM(RTRIM(Email))) ELSE NULL END,
    UPPER(LEFT(LTRIM(RTRIM(Sehir)),1)+LOWER(SUBSTRING(LTRIM(RTRIM(Sehir)),2,50)),
    TRY_CAST(REPLACE(REPLACE(Tutar, '.', ''), ',', '.')) AS DECIMAL(12,2)),
    TRY_CONVERT(DATE, LTRIM(RTRIM(Tarih)), 23),

    UPPER(LEFT(LTRIM(RTRIM(UrunKategori)),1)+LOWER(SUBSTRING(LTRIM(RTRIM(UrunKategori)),2,50)),
    CONCAT_WS('; ',
        CASE WHEN NULLIF(LTRIM(RTRIM(Musteri)), '') IS NULL THEN 'Musteri bos' END,
        CASE WHEN LOWER(Email) NOT LIKE '%_@_%._%' THEN 'Email gecersiz' END,
        CASE WHEN TRY_CAST(REPLACE(REPLACE(Tutar, '.', ''), ',', '.')) AS DECIMAL(12,2)) IS NULL
            THEN 'Tutar gecersiz'
            WHEN TRY_CAST(REPLACE(REPLACE(Tutar, '.', ''), ',', '.')) AS DECIMAL(12,2))<0
            THEN 'Tutar negatif' END,
        CASE WHEN TRY_CONVERT(DATE, LTRIM(RTRIM(Tarih)), 23) IS NULL THEN 'Tarih gecersiz' END)
FROM dbo.Staging_Satis;

SELECT SatisID, AdSoyad, Sehir, Tutar, SatisTarihi, HataNotu FROM dbo.Stg_Temiz;
```

SatisID	AdSoyad	Sehir	Tutar	SatisTarihi	HataNotu
1	Ahmet Yilmaz	Istanbul	1250.00	2024-03-01	
2	ayse demir	Istanbul	990.00	NULL	Tarih gecersiz
3	Mehmet	Ankara	NULL	2024-03-03	Email gecersiz; Tutar gecersiz
4	Ahmet Yilmaz	Istanbul	1250.00	2024-03-01	
5	Fatma Kaya	Izmir	-50.00	NULL	Email gecersiz; Tutar negatif; Tarih gecersiz
6	NULL	Bursa	750.00	2024-03-05	Musteri bos

(6 rows affected) — Boşluklar temizlendi, şehirler standartlaştı, hatalar işaretlendi.

► SONUÇ (RESULTS)

Dikkat: Boşluklar gitti, şehir adları standartlaştı (Istanbul), sayı formatı düzeldi (1.250,00 → 1250.00). Hatalı satırlar **HataNotu** sütununda etiketlendi.

5.2 Yinelenen kayıtları temizleme

SQL

```
;WITH d AS (  
    SELECT *, ROW_NUMBER() OVER (PARTITION BY AdSoyad, Tutar, SatisTarihi  
                                   ORDER BY SatisID) AS rn  
    FROM dbo.Stg_Temiz WHERE HataNotu = '')  
DELETE FROM d WHERE rn > 1;
```

(1 row affected)

SatisID=4, SatisID=1 ile ayni satis oldugu icin silindi (duplicate).

► MESAJLAR (MESSAGES)

5.3 Eksik kategori politikası

SQL

```
UPDATE dbo.Stg_Temiz SET Kategori = N'Bilinmiyor'  
WHERE Kategori IS NULL AND AdSoyad IS NOT NULL;
```

(0 rows affected)

Not: SatisID=6 zaten 'Musteri bos' nedeniyle reddedilecek; kategori doldurma bu satira islemedi.

► MESAJLAR (MESSAGES)

6. Bölüm C – LOAD

Yalnızca **temiz** (HataNotu boş) kayıtlar boyut ve olgu tablolarına yüklenir.

SQL

```
INSERT INTO dbo.DimKategori (KategoriAdi)  
SELECT DISTINCT Kategori FROM dbo.Stg_Temiz s  
WHERE s.HataNotu='' AND NOT EXISTS  
    (SELECT 1 FROM dbo.DimKategori k WHERE k.KategoriAdi=s.Kategori);  
  
INSERT INTO dbo.DimMusteri (AdSoyad, Email, Sehir)  
SELECT DISTINCT s.AdSoyad, s.Email, s.Sehir FROM dbo.Stg_Temiz s  
WHERE s.HataNotu='' AND NOT EXISTS  
    (SELECT 1 FROM dbo.DimMusteri m WHERE m.AdSoyad=s.AdSoyad);  
  
INSERT INTO dbo.FactSatis (MusteriKey, KategoriKey, Tutar, SatisTarihi)  
SELECT m.MusteriKey, k.KategoriKey, s.Tutar, s.SatisTarihi  
FROM dbo.Stg_Temiz s  
JOIN dbo.DimMusteri m ON m.AdSoyad=s.AdSoyad  
JOIN dbo.DimKategori k ON k.KategoriAdi=s.Kategori  
WHERE s.HataNotu='';
```

```
(1 row affected) -- DimKategori: Elektronik
(1 row affected) -- DimMusteri: Ahmet Yilmaz
(1 row affected) -- FactSatis: 1 temiz satis kaydi yuklendi
```

► MESAJLAR (MESSAGES)

Yüklenen olgu tablosunun son hali:

SQL

```
SELECT f.SatisKey, m.AdSoyad, k.KategoriAdi, f.Tutar, f.SatisTarihi
FROM dbo.FactSatis f
JOIN dbo.DimMusteri m ON m.MusteriKey=f.MusteriKey
JOIN dbo.DimKategori k ON k.KategoriKey=f.KategoriKey;
```

SatisKey	AdSoyad	KategoriAdi	Tutar	SatisTarihi
1	Ahmet Yilmaz	Elektronik	1250.00	2024-03-01

(1 row affected) — Yalnızca tüm kontrolleri geçen kayıt ambara ulaştı.

► SONUÇ (RESULTS)

7. Bölüm D – Veri Kalitesi Raporu

SQL

```
SELECT
  (SELECT COUNT(*) FROM dbo.Staging_Satis) AS HamKayit,
  (SELECT COUNT(*) FROM dbo.Stg_Temiz WHERE HataNotu<>'') AS HataliKayit,
  (SELECT COUNT(*) FROM dbo.FactSatis) AS YuklenenTemiz;

SELECT HataNotu, COUNT(*) AS Adet FROM dbo.Stg_Temiz
WHERE HataNotu<>' ' GROUP BY HataNotu ORDER BY Adet DESC;
```

HamKayit	HataliKayit	YuklenenTemiz
6	3	1

(1 row affected) — genel özet

► SONUÇ (RESULTS)

HataNotu	Adet
Email gecersiz; Tutar negatif; Tarih gecersiz	1
Email gecersiz; Tutar gecersiz	1
Musteri bos	1

(3 rows affected) — hata türü dağılımı

► SONUÇ (RESULTS)

8. ETL'i Tekrarlanabilir Yapma

Tüm süreç bir saklı yordama alınarak Proje 7'deki SQL Server Agent ile zamanlanabilir hale getirilir.

SQL

```
CREATE OR ALTER PROCEDURE dbo.usp_ETL_Satis AS
BEGIN
    SET NOCOUNT ON;
    TRUNCATE TABLE dbo.Stg_Temiz;
    -- (Transform + Load adimlari buraya alinir)
END;
GO
EXEC dbo.usp_ETL_Satis;
```

Commands completed successfully.
usp_ETL_Satis calistirildi – sure: 00:00:00.214

► MESAJLAR (MESSAGES)

9. Sonuç

Ham, hatalı ve tutarsız bir satış veri seti klasik Extract–Transform–Load adımlarıyla işlenmiştir. Boşluk/harf standardizasyonu, sayı ve tarih format düzeltmeleri, e-posta doğrulaması, eksik değer politikaları ve yinelenen kayıt temizliği uygulanmış; temiz veri normalize bir ambara yüklenmiştir. Süreç sonunda veri kalitesi raporu ile öncesi/sonrası fark ölçülebilir biçimde gösterilmiştir.